

Politechnika Wrocławska
Wydział Informatyki i Telekomunikacji

Kierunek: Informatyka Stosowana (IST)

Specjalność: Zastosowania Specjalistycznych Technologii Informatycznych (ZSTI)

PRACA DYPLOMOWA
MAGISTERSKA

Wykrywanie Fake News przy użyciu metod
zespołowego uczenia maszynowego

Vadym Liss

Opiekun pracy
Dr inż. Bernadetta Maleszka

Słowa kluczowe: uczenie maszynowe, Fake News, sztuczna inteligencja

WROCŁAW 2025

STRESZCZENIE

Od wiosny 2022 roku uczenie maszynowe zyskało ogromną popularność jako narzędzie do rozwiązywania szerokiego zakresu problemów. Zarówno duże korporacje technologiczne, jak i małe zespoły oraz indywidualni użytkownicy dążą do integracji sztucznej inteligencji w swoich produktach i aplikacjach. Niezależnie od poziomu wiedzy technicznej, coraz więcej osób dostrzega rosnącą rolę SI w niemal każdej dziedzinie. Chociaż rozwój ten niesie wiele korzyści, wiąże się również z poważnymi zagrożeniami. Rozpowszechnienie sztucznej inteligencji ułatwiło tworzenie i dystrybucję treści dezinformacyjnych, co zagraża obiektywizmowi i może prowadzić do manipulacji informacjami. W jednym z najnowszych badań [?] autorzy zwracają uwagę na narastający problem fałszywych wiadomości w mediach społecznościowych. Pomimo postępów w dziedzinie sztucznej inteligencji, wykrywanie i przeciwdziałanie dezinformacji pozostaje znaczącym wyzwaniem. Niniejszy przegląd analizuje obecne metody oraz przyszłe kierunki rozwoju w walce z tym kluczowym problemem. W ramach tej pracy przeprowadzono przegląd istniejących metod i narzędzi służących do ograniczania treści dezinformacyjnych, ze szczególnym uwzględnieniem ich praktycznego zastosowania w XXI wieku. Zaproponowane rozwiązania opierają się na odpowiednim przetwarzaniu i modyfikacji danych wejściowych, co umożliwi lepszą klasyfikację treści. Praca ta obejmuje przegląd wybranych metod zespołowego uczenia maszynowego do wykrywania i klasyfikacji fałszywych wiadomości, ich implementację, przeprowadzenie testów oraz propozycję nowych rozwiązań. Ostatecznym wynikiem jest analiza porównawcza, uwzględniająca specyfikę różnych źródeł danych i zastosowanych metod.

ABSTRACT

Since the spring of 2022, machine learning has gained tremendous popularity as a tool for addressing a wide range of problems. Both large technology corporations and small teams or individuals are increasingly striving to integrate artificial intelligence into their products and applications. Regardless of their technical expertise, more and more people recognize the rapidly growing role of AI in nearly every domain. While this development brings numerous benefits, it also poses significant challenges. The widespread adoption of AI has facilitated the production and dissemination of disinformation, threatening objecti-

vity and potentially leading to information manipulation. In a recent study by Aimeur et al. (2023), the authors highlight the escalating issue of fake news on social media platforms. Despite progress in artificial intelligence, detecting and countering disinformation remains a formidable challenge. This review examines current methods and explores future directions for tackling this critical problem. This work provides a comprehensive overview of existing methods and tools designed to mitigate disinformation, emphasizing their practical applications in the 21st century. The proposed solutions rely on effective processing and modification of input data to improve content classification. In this paper, we review selected ensemble machine learning methods for detecting and classifying fake news, implement these techniques, conduct tests, and propose new solutions. The final result is a comparative analysis that accounts for the specificities of various data sources and the methods applied.

SPIS TREŚCI

1. Wstęp	2
2. Przegląd literatury	4
2.1. Korzyści zastosowania metod zespołowego uczenia maszynowego	4
2.2. Wprowadzenie do metod zespołowych	5
2.2.1. Wyjaśnienie idei za tymi technikami	5
2.2.2. Dlaczego są skuteczne w wykrywaniu fake newsów?	6
2.2.3. Ważne pojęcia	7

1. WSTĘP

Tematem niniejszej pracy magisterskiej jest *Wykrywanie Fake News przy użyciu metod zespołowego uczenia maszynowego*. Problem dezinformacji, w tym tak zwanego fake news, jest jednym z najpoważniejszych wyzwań współczesnego społeczeństwa informacyjnego.

Motywacją do podjęcia tego tematu wynika z realnych zagrożeń, jakie niesie za sobą dezinformacja oraz potrzeby opracowania skutecznych narzędzi do jej zwalczania. W ostatnich latach zaobserwowano liczne przypadki wpływu **fake news** na wyniki wyborów, podziały społeczne czy reakcje na kryzysy zdrowotne, takie jak pandemia COVID-19. Informacje nieprawdziwe, ale celowo rozpowszechniane, potrafią wywoływać panikę, dezinformować w kluczowych sprawach publicznych, a nawet prowadzić do eskalacji konfliktów międzynarodowych. W tym kontekście rola zaawansowanych technologii informatycznych w przeciwdziałaniu tym zjawiskom staje się kluczowa.

Dodatkową motywacją do podjęcia tematu jest rosnące zainteresowanie zastosowaniem sztucznej inteligencji w analizie danych tekstowych oraz ciągła potrzeba udoskonalania istniejących rozwiązań. Współczesne systemy detekcji **fake news** często bazują na standardowych algorytmach, które, mimo wysokiej popularności, nie zawsze radzą sobie w sytuacjach wymagających analizy danych o dużej zmienności, nierównowadze klas czy subtelnych różnicach semantycznych. Opracowanie nowych metod, które potrafią efektywnie radzić sobie z tymi wyzwaniami, może znacząco przyczynić się do zwiększenia skuteczności detekcji **fake news**.

W odpowiedzi na te wyzwania, dziedzina sztucznej inteligencji, a w szczególności uczenie maszynowe, oferuje zaawansowane narzędzia umożliwiające skuteczne wykrywanie i klasyfikację dezinformacji. Wśród tych narzędzi szczególną rolę odgrywają metody zespołowego **uczenia maszynowego** (*ensemble learning*), które dzięki integracji wyników wielu modeli bazowych, pozwalają na osiągnięcie wyższej dokładności predykcji i większej stabilności wyników. Techniki te, takie jak **bagging**, **boosting** czy **stacking**, zdobyły uznanie dzięki swojej skuteczności w rozwiązywaniu problemów nierównowagi klas oraz w zadaniach wymagających analizy dużych i zróżnicowanych zbiorów danych.

Celem niniejszej pracy jest opracowanie i implementacja autorskich metod zespołowego uczenia maszynowego dedykowanych do detekcji **fake news** oraz analiza ich skuteczności w porównaniu z tradycyjnymi podejściami. Praca koncentruje się na tworzeniu innowacyjnych rozwiązań, które wykraczają poza standardowe techniki. Szczególny nacisk położono na projektowanie algorytmów i użycie modeli które łączą w sobie no-

woczesne podejścia do przetwarzania języka naturalnego z zaawansowanymi technikami optymalizacji wyników klasyfikacji.

Główne założenia pracy obejmują:

1. Opracowanie nowych metod zespołowych wykorzystujących.
2. Analizę efektywności autorskich rozwiązań w kontekście kluczowych miar, takich jak **Log Loss**, **Accuracy** i **Execution Time**.
3. Praktyczne zastosowanie proponowanych metod na różnych zbiorach danych zawierających fałszywe i prawdziwe wiadomości, w tym na benchmarkowych zestawach, takich jak ISOT Fake News Dataset i innych.

Celem pracy jest również zbadanie, które podejścia w ramach metod zespołowych okazują się najskuteczniejsze w detekcji dezinformacji oraz jak innowacyjne rozwiązania mogą przyczynić się do dalszego zwiększenia efektywności tych systemów. Dzięki temu niniejsze badania mają na celu nie tylko teoretyczne rozwinięcie wiedzy w obszarze wykrywania **fake news**, ale również dostarczenie praktycznych narzędzi, które mogą być wykorzystywane zarówno w badaniach naukowych, jak i w zastosowaniach przemysłowych.

Wykrywanie fake news to złożone zadanie, które wymaga nie tylko zaawansowanych algorytmów, ale także odpowiedniego przetwarzania danych wejściowych. Przedstawione w tej pracy podejścia bazują się na połączeniu między tradycyjnymi technikami uczenia maszynowego a nowoczesnymi metodami przetwarzania języka naturalnego. W efekcie celem pracy jest stworzenie kompleksowego obrazu możliwości i ograniczeń współczesnych metod zespołowych w wykrywaniu **fake news**, a także wskazanie dalszych kierunków rozwoju w tym obszarze.

Niniejsze badania mają na celu nie tylko teoretyczne rozwinięcie wiedzy w obszarze wykrywania fake news, ale również dostarczenie praktycznych narzędzi, które mogą być wykorzystywane zarówno w badaniach naukowych, jak i w zastosowaniach komercyjnych.

Praca ta stanowi próbę odpowiedzi na pytanie, które podejścia w ramach metod zespołowych okazują się najskuteczniejsze w detekcji dezinformacji, oraz jakie innowacyjne rozwiązania mogą jeszcze bardziej zwiększyć efektywność takich systemów. Dzięki temu niniejsze badania przyczynią się do rozwinięcia narzędzi, które mogą być wykorzystywane zarówno w badaniach naukowych, jak i w praktycznych zastosowaniach w walce z dezinformacją.

2. PRZEGLĄD LITERATURY

2.1. KORZYŚCI ZASTOSOWANIA METOD ZESPOŁOWEGO UCZENIA MASZYNOWEGO

Jak wspomniano w podanym artykule [?], **ensemble learning** to metoda uczenia maszynowego, która polega na łączeniu wyników wielu modeli w celu poprawy dokładności predykcji. Główne klasy metod ensemble learning obejmują **bagging**, **boosting**, **stacking** oraz inne. Każda z tych technik znajduje zastosowanie w rozwiązaniu problemów nierównowagi klas (class imbalance), gdzie liczba próbek jednej klasy jest znacznie większa od liczby próbek drugiej klasy. Takie sytuacje mogą prowadzić do stronniczości modeli maszynowych na korzyść klasy większościowej, co prowadzi do błędnej klasyfikacji próbek klasy mniejszościowej. Bardziej szczegółowy opis wspomnianych powyżej metod zostanie omówiony w następnym podrozdziale.

W artykule wykazano, że metody ensemble są szczególnie skuteczne w przypadku danych nierównoważnych, takich jak:

- Wykrywanie oszustw (fraud detection),
- Analiza sentymentu,
- Diagnostyka medyczna,
- Prognozowanie awarii urządzeń.

W porównaniu do pojedynczych modeli, metody zespołowe osiągają lepsze wyniki zarówno w metrykach klasyfikacyjnych, jak i ogólnej dokładności. Ponadto, odpowiednio zaprojektowane metody ensemble mogą redukować problem nadmiernego dopasowania (overfitting). Chcielibyśmy wyróżnić następujące **zalety** stosowania metod zespołowego uczenia maszynowego:

- **Zwiększona odporność na błędy:** Ensemble learning zmniejsza ryzyko błędów spowodowanych nadmierną wariancją lub stronniczością pojedynczych modeli, co zapewnia bardziej stabilne i wiarygodne wyniki.
- **Integracja różnorodnych modeli:** Możliwość łączenia różnych typów modeli pozwala na wykorzystanie ich indywidualnych mocnych stron, co zwiększa skuteczność w zadaniach klasyfikacyjnych i regresyjnych.
- **Skuteczność w rozwiązywaniu problemów nierównowagi klas:** Ensemble learning wykazuje lepsze wyniki w zadaniach z nierównomiernym rozkładem klas, zwłaszcza

gdzie jest stosowany w połączeniu z metodami wzbogacania danych, takimi jak SMOTE czy generatywne sieci przeciwstawne (GANs).

2.2. WPROWADZENIE DO METOD ZESPOŁOWYCH

2.2.1. Wyjaśnienie idei za tymi technikami

Rozszerzając wiedzę na temat technik metod zespołowego uczenia maszynowego, szeroko opisanych w artykule [?], można zauważyć ich uniwersalność i znaczenie w różnych zastosowaniach. Jak wskazano w artykule, sukces tych metod wynika z ich zdolności do redukowania błędów systematycznych (bias) i wariancji, efektywnego wykorzystania zasobów obliczeniowych oraz umiejętności reprezentowania bardziej złożonych zależności w danych. W praktyce metody ensemble znajdują zastosowanie w wielu dziedzinach, takich jak diagnostyka medyczna, analiza obrazów, wykrywanie anomalii czy przewidywanie awarii urządzeń. Autorzy podkreślają również ich skuteczność w rozwiązywaniu problemów nierównowagi klas, co jest szczególnie istotne w zadaniach, gdzie jedna klasa danych jest znacząco mniej reprezentowana.

Dzięki integracji z modelami głębokiego uczenia, metody zespołowe łączą zdolność do hierarchicznego uczenia reprezentacji z większą precyzją predykcji. Jednocześnie rozwój tych modeli wymaga rozwiązywania wyzwań, takich jak wysoki koszt obliczeniowy oraz konieczność zapewnienia różnorodności pomiędzy modelami bazowymi, co pozwala na ich skuteczne wykorzystanie w praktyce.

Bagging (Bootstrap Aggregating)

Bagging, znany także jako bootstrap aggregating, to metoda redukująca wariancję modeli bazowych poprzez trenowanie ich na różnych, losowych próbkach danych wybranych z zamianą (bootstrap). Jak wspomniano w artykule, bagging polega na tworzeniu wielu niezależnych modeli bazowych, których wyniki są następnie łączone poprzez głosowanie większościowe (w przypadku klasyfikacji) lub uśrednianie (w przypadku regresji).

Przykładem zastosowania baggingu jest **Random Forest**, w którym dodatkowo losowo wybierane są podzbiory cech na każdym etapie budowania drzewa decyzyjnego. W ten sposób zwiększa się różnorodność modeli bazowych, zmniejszając jednocześnie ryzyko nadmiernego dopasowania i poprawiając stabilność wyników.

Boosting

Boosting to metoda polegająca na iteracyjnym trenowaniu modeli, gdzie każdy kolejny model skupia się na przykładach trudnych do sklasyfikowania przez poprzedników. W artykule podkreślono, że proces ten umożliwia tworzenie silnych klasyfikatorów zdolnych do radzenia sobie z bardziej złożonymi problemami.

Przykładem jest **AdaBoost**, który nadaje większe wagi błędnie sklasyfikowanym przykładom w kolejnych iteracjach, minimalizując funkcję błędu eksponencjalnego. Natomiast **Gradient Boosting** rozszerza to podejście, optymalizując dowolną różniczkowalną funkcję błędu. Boosting efektywnie redukuje błąd systematyczny (bias) i wariancję, co prowadzi do lepszych wyników.

Stacking (Stacked Generalization)

Stacking, czyli uogólnione zestawianie (stacked generalization), to metoda zespołowa, w której różne modele bazowe są łączone za pomocą meta-modelu. Meta-model uczy się, jak najlepiej łączyć prognozy modeli bazowych, korzystając z ich wyników jako danych wejściowych.

Jak podano w artykule, stacking pozwala na łączenie różnych typów modeli (np. drzewa decyzyjne, sieci neuronowe, SVM), co czyni go bardziej elastycznym i zdolnym do generalizacji. W literaturze metoda ta jest również stosowana w złożonych problemach, takich jak klasyfikacja obrazów czy przewidywanie trendów.

Negative Correlation Learning (NCL)

W technice **Negative Correlation Learning (NCL)** dąży się do zwiększenia różnorodności wśród modeli bazowych poprzez wprowadzenie funkcji kosztu, która karze zbyt podobne prognozy między modelami. W artykule podkreślono, że metoda ta jest szczególnie skuteczna w problemach wymagających wysokiej zdolności do generalizacji.

Przykładem zastosowania NCL są zadania regresyjne i klasyfikacyjne, w których różnorodność modeli poprawia ogólną wydajność zespołu.

Homogeniczne i heterogeniczne zespoły

- **Homogeniczne zespoły:** Wykorzystują jeden typ klasyfikatorów (np. drzewa decyzyjne w Random Forest). Kluczowym wyzwaniem jest wprowadzenie różnorodności, np. poprzez losowe próbkowanie danych treningowych lub cech.
- **Heterogeniczne zespoły:** Łączą różne typy modeli (np. sieci neuronowe, SVM, regresję logistyczną). Są bardziej elastyczne i zdolne do uchwycenia różnych cech danych, co czyni je użytecznymi w złożonych problemach, takich jak analiza tekstu czy przewidywanie awarii.

2.2.2. Dlaczego są skuteczne w wykrywaniu fake newsów?

Bagging (Bootstrap Aggregating)

Bagging zwiększa stabilność modeli w sytuacjach, gdy dane są niestabilne lub różnorodne – co jest powszechne w zadaniach wykrywania fake news. Przykładem jest Random Forest, który dzięki losowemu wyborowi podzbiorów cech i danych jest odporny

na przetrenowanie, co pozwala mu skutecznie radzić sobie z różnymi rodzajami tekstów. Redukcja wariancji umożliwia bardziej spójne klasyfikowanie nawet w przypadku danych zawierających subtelne różnice.

Boosting

Boosting koncentruje się na trudno klasyfikowalnych przykładach, które są częste w zbiorach danych dotyczących fake news. Fałszywe informacje często charakteryzują się subtelnymi manipulacjami w języku, co wymaga modeli zdolnych do uchwycenia takich szczegółów. Boosting, np. w formie Gradient Boostingu lub XGBoost, jest w stanie modelować złożone zależności między cechami, co prowadzi do wyższej dokładności w identyfikowaniu fałszywych wiadomości.

Stacking (Stacked Generalization)

Stacking umożliwia łączenie różnych metod analizy tekstu, takich jak modele oparte na n-gramach, TF-IDF, czy głębokie sieci neuronowe. Dzięki temu można wykorzystać mocne strony każdego z tych podejść, jednocześnie minimalizując ich słabości. W zadaniach wykrywania fake news stacking pozwala połączyć modele bazujące na różnych źródłach danych (np. tekst, metadane, analiza kontekstu), co daje bardziej kompleksowy obraz problemu.

Negative Correlation Learning (NCL)

NCL zwiększa różnorodność modeli bazowych, co sprawdza się w wykrywaniu fake news, gdzie dane są niejednorodne i zawierają różnorodne wzorce. Dzięki promowaniu różnorodności w predykcjach, modele uczą się szerokiego zakresu cech, co prowadzi do lepszego uogólnienia wyników na danych testowych.

Homogeniczne i heterogeniczne zespoły

Homogeniczne zespoły, dobrze radzą sobie z dużą liczbą cech tekstowych i ich interakcjami. Z kolei heterogeniczne zespoły, łączące różne typy modeli, pozwalają lepiej uchwycić różnorodne cechy danych fake news, takie jak manipulacyjny język, brak źródeł czy określone wzorce emocjonalne w tekstach.

2.2.3. Ważne pojęcia

Binary Cross-Entropy to sposób mierzenia, jak dobrze coś jest klasyfikowane na dwie grupy, na przykład czy wiadomość jest prawdziwa, czy fałszywa. W praktyce pomaga sprawdzić, czy nasze przewidywania są bliskie rzeczywistości – im mniejszy błąd, tym lepiej rozróżniamy te dwie kategorie, co jest kluczowe w analizie wiarygodności treści.

Early Stopping Rounds to technika, która pozwala zatrzymać proces uczenia, gdy dalsze próby nie przynoszą poprawy. Wyobraźmy sobie, że uczymy się rozpoznawać

fałszywe wiadomości: jeśli po kilku rundach nie robimy postępów, przerywamy, aby nie tracić czasu i nie skupiać się za bardzo na szczegółach, które mogą być mylące w nowych sytuacjach.

Random State zapewnia, że losowe wybory, na przykład podział danych na grupy do analizy, są zawsze takie same. Dzięki temu wyniki badań są powtarzalne – jeśli analizujemy wiadomości, możemy być pewni, że za każdym razem pracujemy na tych samych zestawach, co ułatwia porównanie i zapewnia spójność.